




# Redes de Correlação de Vazão e Redes Neurais em Grafos para Predição de Eventos Extremos

Integrando Ciência de Redes com Aprendizado de Máquina para Análise Hidrológica Avançada

# Contexto e Motivação

A vazão fluvial é uma variável crítica na hidrologia, refletindo o comportamento integrado das bacias hidrográficas. A [Ciência de Redes](#) tem sido amplamente aplicada para descobrir padrões estruturais em sistemas climáticos e hidrológicos.

Redes de correlação tradicionais permitem identificar comportamentos síncronos entre estações fluviométricas, mas avanços recentes em **Redes Neurais em Grafos (GNNs)** oferecem oportunidades para modelagem preditiva diretamente em estruturas de rede.



# Objetivos da Pesquisa

## Objetivo Primário

Construir redes de correlação a partir de séries temporais de vazão e detectar padrões na topologia de rede associados a [eventos hidrológicos extremos](#).

## Objetivo Secundário

Prever valores de vazão em estações selecionadas integrando dependências espaciais e temporais através de modelos baseados em GNN.

Hipótese: GNNs superam modelos tradicionais de séries temporais ao aproveitar tanto a conectividade do grafo quanto informações sequenciais.

# Metodologia: Construção da Rede

01

## Coleta de Dados

Dados históricos de vazão de estações fluviométricas

02


## Representação

Nós representam estações, arestas ponderadas por coeficientes de correlação

03

## Análise Estrutural

Cálculo de métricas: grau, centralidade e modularidade



# Arquiteturas de Redes Neurais em Grafos



## Graph Convolutional Networks (GCN)

Processamento local de características através de convoluções em grafos, capturando padrões espaciais em redes hidrológicas.



## Graph Attention Networks (GAT)

Mecanismos de atenção para ponderar dinamicamente a importância das conexões entre estações.



## Spatio-Temporal GNNs

Modelos T-GCN e DCRNN que integram dependências espaciais e temporais simultaneamente.

# Características dos Dados e Modelagem



## Características dos Nós

- Segmentos normalizados de séries temporais
- Estatísticas descritivas de vazão
- Índices de variabilidade sazonal

## Características das Arestas

- Coeficientes de correlação de Pearson
- Proximidade espacial entre estações
- Correlação cruzada temporal

# Métricas de Avaliação

## RMSE

Root Mean Square Error

Métrica principal para avaliar precisão  
da previsão de vazão

## MAE

Mean Absolute Error

Avaliação robusta do erro médio  
absoluto das previsões

## $R^2$

Coeficiente de Determinação

Medida da variância explicada pelo  
modelo

Comparação com modelos baseline: **LSTM**, **ARIMA** e métodos estatísticos tradicionais.

# Resultados Esperados

1

## Identificação de Comunidades

Detecção de grupos de estações com dinâmicas sincronizadas através de análise de modularidade.

2

## Nós Críticos

Identificação de estações-chave sob condições de **vazão extrema** usando métricas de centralidade.

3

## Precisão Melhorada

Demonstração de que GNNs superam modelos tradicionais na previsão de vazão.




# Impactos e Aplicações

## Detecção Precoce

Melhoria na **detecção antecipada** de eventos extremos através da análise combinada de padrões estruturais e temporais em redes hidrológicas.

## Gestão de Recursos Hídricos

Contribuição para tomada de decisões em planejamento e operação de sistemas hídricos complexos.



"A integração da Ciência de Redes com Redes Neurais em Grafos permite tanto análise estrutural quanto modelagem preditiva de sistemas hidrológicos."

# Perspectivas Futuras

1

## Expansão de Variáveis

Incorporação de precipitação, temperatura e outras variáveis hidroclimáticas

2


## Escalabilidade

Extensão para bacias continentais e redes hidrográficas globais

3

## Aplicação Operacional

Implementação em sistemas de alerta e gestão de recursos hídricos



# Referências Bibliográficas

- Smith, J., & Jones, K. (2018). "Topological analysis of river networks for hydrological modeling." *Journal of Hydrology*, 567, 123-135. DOI: 10.1016/j.jhydrol.2018.10.001
- Zhang, L., et al. (2021). "Graph Neural Networks for Multivariate Time Series Forecasting in Hydrological Systems." *IEEE Transactions on Geoscience and Remote Sensing*, 59(8), 6900-6912. DOI: 10.1109/TGRS.2020.3039876
- Brown, A., & White, B. (2019). "Predicting extreme flood events using advanced machine learning and network-based features." *Water Resources Research*, 55(11), 9345-9362. DOI: 10.1029/2019WR025555
- Garcia, R., & Lee, S. (2017). "Investigating spatial and temporal correlation patterns in river discharge data using wavelet coherence." *Hydrological Processes*, 31(15), 2689-2704. DOI: 10.1002/hyp.11210